

Дегтярев Роман

ML Engineer

Москва

Россия

✉ r.degtyarev5@gmail.com

📧 [rdegt00](#)

🐙 [rdegt](#)

Профиль

ML-инженер с опытом end-to-end разработки локального streaming ASR: от данных и обучения RNN-T до оптимизации, TFLite-инференса и production A/B-тестов.

Опыт работы

2026 **ML Engineer, Speech Recognition R&D, Яндекс, Москва**

- Развивал локальный streaming ASR с Transformer encoder и chunkwise attention. Полный цикл: сбор логов, обучение, MWER fine-tuning, TFLite-конвертация, offline-валидация и подготовка моделей к двум A/B-тестам на умных колонках и ТВ. Анализировал качество, latency и системные метрики; найденные проблемы возвращал в следующий цикл данных и обучения.
- Отвечал за направление INT8-квантизации on-device моделей. Разработал пооперационную декомпозицию INT8-ошибки и выявил нетривиальный bottleneck в конвертере. Предложенное исправление снизило WER с 24.61 до 21.15 (−14.1%) без переобучения модели.
- На основе анализа разработал QAT-стратегии и доработал production пайплайн конвертации. QAT дало дополнительное улучшение до **5.7% relative WER**.
- Исследовал расхождение offline метрик и результатов A/B-тестов. Построил feedback loop из A/B-логов: отбор медленных запросов, EOS-разметка и добавление данных в MWER- и EOU-обучение.
- Реализовал варианты parameter sharing весов энкодера. Лучший вариант улучшил **WER на 11.5%** без пропорционального роста числа параметров; оценил компромисс между качеством и RTF и довел решение до streaming инференса с корректным управлением K/V-cache

Образование

2021–2026 **Прикладная математика и информатика, НИУ ВШЭ, Факультет компьютерных наук, Москва**

Исследования и проекты

- Tabular Diffusion Исследовал три диффузионные модели на пяти табличных датасетах для регрессии и классификации. Предложенные иодификации улучшили целевые метрики в среднем на **8%**. Работа представлена на DLCP 2026; статья готовится к публикации.
- NLP Исследовал методы сжатия и parameter-efficient fine-tuning Transformer-моделей: knowledge distillation, low-rank factorization, weight sharing, adapters, LoRA и soft prompts. Проводил domain adaptation BERT и сравнивал компромисс качества, числа параметров и вычислительной стоимости.
- Multimodal ASR Интегрировал аудиомодальность с Qwen3-0.6B для распознавания речи; исследовал способы согласования акустических представлений с языковой моделью.

Навыки

ML PyTorch, TensorFlow/Keras, TFLite, scikit-learn, NumPy, pandas

Специализация Streaming ASR, RNN-T, Transformers, QAT/INT8, knowledge distillation, model compression

Разработка Python, C++, Hadoop, Spark, Docker, SQL/YQL, distributed training, A/B testing

Языки Английский — C1